ДЗ 4. Клиническая аннотация генетических вариантов

ФИО: Шебанов Иван Владимирович, вариант 14

Файлы

- `data/student_14.vcf` — исходный VCF
- `annotate.py` — скрипт аннотации (VEP, ClinVar, gnomAD)
- `annotation_settings.json` — настройки аннотации
- `results/annotated_variants.csv` — итоговая таблица на 50 вариантов
- `results/vep.json`, `results/clinvar.json`, `results/gnomad.json` — ответы VEP, ClinVar и gnomAD
- `report.pdf` — этот отчёт в PDF

Запуск: `python annotate.py data/student_14.vcf results`

Что было сделано

В файле 50 однонуклеотидных замен в координатах GRCh38: 13 на 21-й хромосоме и 37 на 22-й. Транзиций 43, трансверсий 7. Поля QUAL, FILTER и INFO пустые, генотипов нет.

Все варианты прогнал скриптом `annotate.py` через три источника: Ensembl VEP (REST API, релиз 116), ClinVar (через NCBI E-utilities) и gnomAD v4.1 (GraphQL API). Настройки лежат в `annotation_settings.json`. В ClinVar искал по позиции и потом проверял, что у записи тот же ALT: на одной позиции бывают записи с другой заменой. Например, для rs35978693 там есть и G>A, и G>T, а у нас G>T.

У одного варианта обычно несколько транскриптов, и последствия в них бывают разные. Я брал самое тяжёлое последствие по всем транскриптам (как его считает VEP), а среди транскриптов с этим последствием выбирал MANE Select, а если его нет, то canonical. В таблице есть отдельная колонка с последствием в MANE Select, потому что у 7 вариантов они не совпадают.

Что получилось в целом

Все варианты попали в кодирующие участки 23 генов. По самому тяжёлому последствию это 25 missense, 23 синонимичных, один stop_gained и один splice_polypyrimidine_tract. Если смотреть только MANE Select, получается 30 синонимичных и 20 missense: во всех 7 расхождениях «плохое» последствие есть только в альтернативных транскриптах.

В ClinVar нашлись записи для 19 вариантов из 50. Из них 15 benign или likely benign, две VUS (SUSD2 rs116712499 и GAL3ST1 rs114565111), одна с конфликтом (LARGE1 rs113253213), а у одной записи (SMTN rs34292278) классификации пока нет. Патогенных нет.

В gnomAD есть все 50 вариантов. По общей частоте (экзомы и геномы вместе) 15 встречаются с частотой 1% и выше, 12 от 0,1 до 1%, 23 реже 0,1%.

Три варианта подробнее

rs115706909 (chr22:21643926 C>T, SDF2L1)

VEP выдал для него stop_gained, но только в одном транскрипте, ENST00001093571 (c.220C>T, p.Arg74Ter). Это новый транскрипт, первая версия. В основном транскрипте гена (MANE Select, NM_022044.3) та же замена синонимичная: c.417C>T, p.Gly139=. Получается, альтернативный транскрипт читает этот кусок в другой рамке, и там кодон CGA становится стоп-кодоном TGA.

В gnomAD вариант редкий: $9{,}4 \cdot 10^{-5}$ в экзомах и $7{,}0 \cdot 10^{-4}$ в геномах, чаще всего у африканцев (около 0,3%). Есть один гомозиготный носитель. В ClinVar записи нет.

Скорее всего, клинического значения у него нет: по основному транскрипту замена синонимичная, а стоп появляется только в новом альтернативном транскрипте, который не MANE и не canonical. Зато на этом варианте хорошо видно, что от выбора транскрипта зависит ответ.

rs115083767 (chr22:30470253 G>A, SEC14L3)

Missense в MANE Select транскрипте (NM_174975.5): c.133C>T, p.Arg45Trp. Вдобавок вариант попадает в сплайс-регион у границы экзона. Предсказатели считают его вредным: SIFT deleterious (0,05, впритык к порогу), PolyPhen possibly damaging (0,559), AlphaMissense likely pathogenic (0,73). Из 25 missense в наборе AlphaMissense так оценил только его. Сама замена резкая: аргинин заряженный, а триптофан большой и ароматический.

Частота в gnomAD около 10^{-4} ($7{,}2 \cdot 10^{-5}$ в экзомах, $3{,}7 \cdot 10^{-4}$ в геномах), гомозигот нет. В ClinVar записи нет.

По предсказаниям это самый подозрительный вариант в файле. Но SEC14L3 — липид-связывающий белок, с которым не связано ни одно известное наследственное заболевание, а клинических данных по варианту нет. Поэтому больше, чем «неясное значение», тут сказать нельзя.

rs113253213 (chr22:33304315 G>A, LARGE1)

Синонимичная замена во всех транскриптах, где эта позиция попадает в кодирующую часть, в MANE (NM_133642.5) это c.1644C>T, p.Asn548=. В сплайс-регион не попадает.

В ClinVar это запись VCV000095167 со статусом «Conflicting classifications of pathogenicity». Всего 8 заявок, среди оценок есть benign, likely benign и uncertain significance. Заявки касаются мышечной дистрофии-дистрогликанопатии типов A6 и B6, а часть сделана без указания болезни. Последний раз запись пересматривали 22.01.2026.

Частота в gnomAD: $1{,}8 \cdot 10^{-4}$ в экзомах, $1{,}6 \cdot 10^{-3}$ в геномах, у африканцев около 0,5%.

LARGE1 — серьёзный клинический ген: его белок гликозилирует α-дистрогликан, и при поломке обеих копий развиваются тяжёлые рецессивные мышечные дистрофии. Но этот вариант синонимичный, сплайсинг не задевает и для такой редкой болезни встречается слишком часто. Скорее всего, он доброкачественный, а конфликт в ClinVar возник из-за того, что часть заявок поставила VUS.

Заключение

Патогенных вариантов в наборе не нашлось. Большая часть либо синонимичные, либо обычные полиморфизмы, а всё, что есть в ClinVar, оценено как benign, likely benign, VUS или с конфликтом. Интереснее всего три случая. Редкий missense в SEC14L3 все предсказатели считают вредным, хотя ген ни с чем не связан. «Стоп-кодон» в SDF2L1 пропадает при выборе основного транскрипта. Синонимичная замена в LARGE1 имеет конфликт в ClinVar.

У данных есть ограничения. В VCF нет генотипов, поэтому непонятно, в одной копии вариант или в обеих, а для рецессивных генов вроде LARGE1 это решает всё. QUAL и FILTER пустые, то есть про качество секвенирования ничего не известно. Вариантов всего 50 и только на двух хромосомах, фенотипа нет, так что о человеке в целом сказать ничего нельзя.

Сами базы тоже не идеальны. Последствие зависит от выбранного транскрипта, и в новых транскриптах Ensembl встречаются сомнительные missense и стопы. SIFT, PolyPhen и AlphaMissense дают только предсказания и часто расходятся: у rs115180746, например, SIFT пишет deleterious, а PolyPhen benign. В ClinVar нет записей для 31 варианта из 50, а часть имеющихся сделана одним сабмиттером. Частоты в gnomAD заметно отличаются между экзомами и геномами и между популяциями, и участники gnomAD не обязательно здоровы. Наконец, базы обновляются, так что через пару релизов часть ответов может поменяться.